

# 2025년 10월 서울시 지하철 호선별(1호선~9호선), 역별 승하차 인원 정보 및 예측

---

202108126 조민재

# 프로젝트 범위

- 데이터 수집, 크롤링 -> DATA.GO.KR(공공데이터 포털) 지하철/버스 승하차 데이터  
<https://data.seoul.go.kr/>(<https://www.data.go.kr/data/15134550/fileData.do#tab-layer-file>)
- 데이터 저장, 추출 -> CSV + MySQL
- 데이터 가공/정제 -> Pandas
- 데이터 분석 -> python + Scikit-learn
- 데이터 시각화 -> matplotlib

# 데이터 수집 과정

## • 데이터 출처

- 서울 열린데이터 광장(서울시 공공데이터 포털)에서 제공하는 「서울시 지하철 호선별 역별 승하차 인원 정보」 월별 자료 중 2025년 10월 데이터 (CARD\_SUBWAY\_MONTH\_202510.csv)를 사용
- 데이터는 호선별·역별·일별 승차/하차 인원이 집계된 형태로 제공

# 데이터 전처리 과정

## 1. 컬럼 구조

- 사용일자: 승·하차 인원이 집계된 날짜 (문자열 형식, 예: "20251001")
- 노선명: 지하철 노선명 (예: "1호선", "2호선")
- 역명: 지하철역 명칭 (예: "강남", "홍대입구")
- 승차총승객수: 해당 날짜·역·노선의 **승차 인원 합계**
- 하차총승객수: 해당 날짜·역·노선의 **하차 인원 합계**

# 데이터 전처리 과정

## 2. 날짜 형식 변환

- 초기 데이터의 사용일자는 문자열이므로, 시계열 분석을 위해 datetime 타입으로 변환
- 혹시 모를 공백/기타 문자를 제거하기 위해 **숫자만 추출 후 8자리 날짜로 인식하는 방식**을 사용

```
date_str = (
    df['사용일자']
    .astype(str)
    .str.replace(r'[^0-9]', '', regex=True) # 숫자가 아닌 것 제거
    .str.slice(0, 8)                      # 앞 8자리: 20251001
)

df['사용일자'] = pd.to_datetime(date_str, format='%Y%m%d', errors='coerce')
```

# 데이터 전처리 과정

## 3. 결측치 제거

- 분석의 기본 단위가 (날짜, 노선, 역) 이므로, 이 중 어느 하나라도 없는 행은 제거
- 사용일자가 결측인 행을 제거

```
df_clean = df.dropna(subset=['사용일자'])
print("정제 후 df 크기:", df_clean.shape)
print(df_clean.head())
```

# 데이터 전처리 과정

## 4. 파생변수 생성: 총 이용객 수

- 승차와 하차를 합산한 **하루 총 이용객수** 파생 변수 생성
- 날짜별 전체 이용량, 노선별/역별 TOP10, 11월 예측 등 다양한 분석에 사용

```
# 2) 총 이용객수  
df['총이용객수'] = df['승차총승객수'] + df['하차총승객수']
```

# 데이터 변환 과정

## 1. 날짜별 전체 이용객수 집계

- 2025년 10월 한 달 동안의 날짜별 전체 승차/하차/총 이용객수

```
daily = (
    df_clean.groupby('사용일자')[['승차총승객수', '하차총승객수', '총이용객수']]
        .sum()
        .reset_index()
)
```

# 데이터 변환 과정

## 2. 노선별 전체 이용객수 집계

- 노선별 추세를 분석하기 위해 (날짜, 노선) 단위로 총 이용객수를 집계

```
# 노선별 날짜별 총 이용객수 집계
line_daily = (
    df_1to9.groupby(['사용일자', '노선명'])['총이용객수']
    .sum()
    .reset_index()
)
```

# 데이터 변환 과정

## 3. 역별 전체 이용객수 집계

- 어느 역이 가장 많이 이용되는지 확인하기 위해 역 단위 합계를 계산

```
# 노선별 날짜별 총 이용객수 집계
line_daily = (
    df_1to9.groupby(['사용일자', '노선명'])['총미용객수']
    .sum()
    .reset_index()
)
```

# 데이터 변환 과정

## 4. 2025년 11월 승·하차 인원 예측

-각(노선, 역) 조합에 대해 과거 10월 데이터의 day\_idx(x)와 승차/하차 인원(y)을 사용해 **1차 회귀(추세선)**를 구하거나,  
데이터가 부족하거나 변동이 거의 없을 경우 **평균값**으로 예측치를 설정

```
pred_rows = []

for (line, station), g in station_daily.groupby(['노선명', '역명']):
    x = g['day_idx'].values.astype(float)

    # 승차/하차 각각에 대해 예측
    for col in ['승차총승객수', '하차총승객수']:
        y = g[col].values.astype(float)

        if len(g) >= 3 and np.std(y) > 0:
            # 데이터가 어느 정도 있으면 1차 회귀 (y = a+x + b)
            a, b = np.polyfit(x, y, 1)
            y_future = a * future_idx + b
        else:
            # 데이터가 너무 적거나 변화가 거의 없으면 평균값 사용
            y_future = np.full_like(future_idx, y.mean())

        # 음수 예측치 방지
        y_future = np.where(y_future < 0, 0, y_future)

        # 결과 쌍기
        for d, idx_val, y_hat in zip(future_dates, future_idx, y_future):
            pred_rows.append({
                '사용일자': d,
                '노선명': line,
                '역명': station,
                '지표': col,           # 승차/하차 구분
                '예측값': float(y_hat)
            })
```

# 날짜별 지하철 총 이용객수 추세


```
NaN 개수:  
사용일자      0  
승차총승객수   0  
하차총승객수   0  
총이용객수    0  
dtype: int64  
형 변환 후 dtypes:  
사용일자      datetime64[ns]  
노선명        string[python]  
역명          string[python]  
승차총승객수   int64  
하차총승객수   int64  
등록일자      int64  
총이용객수    int64  
dtype: object  
정제 후 df 크기: (19127, 7)  
사용일자 노선명 역명 승차총승객수 하차총승객수  
0 2025-10-01 7호선 중계 18030 16820 20251004 34850  
1 2025-10-01 1호선 종로3가 27337 24307 20251004 51644  
2 2025-10-01 1호선 종로5가 25140 24649 20251004 49789  
3 2025-10-01 1호선 동대문 12569 11849 20251004 24418  
4 2025-10-01 1호선 신설동 16055 15400 20251004 31455  
daily head:  
사용일자 승차총승객수 하차총승객수 총이용객수  
0 2025-10-01 8140983 8109833 16250816  
1 2025-10-02 8324026 8288301 16612327  
2 2025-10-03 4985484 4958004 9943488  
3 2025-10-04 4693101 4665185 9358286  
4 2025-10-05 3342252 3318936 6661188
```

등록일자 총이용객수



# 노선별 날짜별 총 이용객수 추이

... 필터링된 노선 목록: <StringArray>  
['7호선', '1호선', '2호선', '3호선', '4호선', '5호선', '6호선', '8호선', '9호선']  
Length: 9, dtype: string



# 역별 이용객수 TOP10

... 역별 이용객수 TOP10		
	역명	총이용객수
251	서울역	6758534
428	잠실(송파구청)	5843573
517	홀대입구	5785338
35	고속터미널	5119536
11	강남	4261408
218	사당	3855676
261	선릉	3506428
309	신림	3241352
445	종로3가	3169350
267	성수	3128438



# 2025년 11월 서울시 승하차 인원 예측

... 원본 station\_daily 예시:

	사용일자	노선명	역명	승차총승객수	하차총승객수	day_idx
0	2025-10-01	1호선	동대문	12569	11849	0
1	2025-10-01	1호선	동묘앞	9759	10188	0
2	2025-10-01	1호선	서울역	73447	73541	0
3	2025-10-01	1호선	시청	31346	31054	0
4	2025-10-01	1호선	신설동	16055	15400	0

== 2025년 11월 역별/노선별 승하차 인원 예측 예시 (상위 10개) ==

지표	사용일자	노선명	역명	승차총승객수	하차총승객수	총미용객수_예측
0	2025-11-01	1호선	동대문	13859.967742	13330.664516	27190.632258
1	2025-11-01	1호선	동묘앞	11573.251613	11907.612903	23480.864516
2	2025-11-01	1호선	서울역	87697.083871	81507.541935	169204.625806
3	2025-11-01	1호선	시청	33022.058065	33233.619355	66255.677419
4	2025-11-01	1호선	신설동	16766.754839	16205.154839	32971.909677
5	2025-11-01	1호선	제기동	18292.883871	18578.916129	36871.800000
6	2025-11-01	1호선	종각	46502.619355	45609.412903	92112.032258
7	2025-11-01	1호선	종로3가	30003.348387	26718.135484	56721.483871
8	2025-11-01	1호선	종로5가	27932.638710	27544.064516	55476.703226
9	2025-11-01	1호선	청량리(서울시립대입구)	25766.806452	25685.400000	51452.206452

역/노선별로 간단한 1차 추세선과 평균을 기반으로 예측